

# Решение систем линейных уравнений

С.В. Лемешевский (sergey.lemeshevsky@gmail.com)

Институт математики НАН Беларуси

Nov 13, 2018

## Содержание

<b>1 Прямые методы линейной алгебры</b>	<b>2</b>
1.1 Метод исключения Гаусса . . . . .	2
1.2 Методы решения систем с симметричными матрицами	12
<b>2 Итерационные методы решения систем линейных алгебраических уравнений</b>	<b>14</b>
2.1 Стандартные итерационные методы . . . . .	14
2.2 Метод сопряженных градиентов . . . . .	17
<b>3 Тестирование реализации методов</b>	<b>19</b>
<b>4 Задачи</b>	<b>19</b>
1: Решение системы линейных уравнений с трехдиагональной матрицей . . . . .	19
2: Метод Гаусса с частичным выбором ведущего элемента	20
3: Разложение Холецкого . . . . .	20
4: Метод Якоби . . . . .	20
5: Метод Зейделя . . . . .	21
6: Сравнение методов Якоби и Зейделя . . . . .	21
7: Метод верхней релаксации . . . . .	21
8: Метод сопряженных градиентов . . . . .	21
<b>Предметный указатель</b>	<b>22</b>

Проблема решения линейной системы

$$Ax = b \quad (1)$$

является центральной в научных вычислениях. В этой главе мы остановимся на методах решения систем вида (1). Сначала остановимся на методе исключения Гаусса, а затем рассмотрим некоторые итерационные методы.

## 1. Прямые методы линейной алгебры

Одной из основных задач вычислительной математики является проблема решения систем линейных алгебраических уравнений с вещественными коэффициентами. Для нахождения приближенного решения систем уравнений используются прямые и итерационные методы. Математический аппарат линейной алгебры базируется на понятиях нормы вектора и матрицы, числа обусловленности. Рассматриваются классические методы исключения неизвестных, отмечаются особенности решения задач с симметричной вещественной матрицей.

### 1.1. Метод исключения Гаусса

Начнем с обсуждения того, как можно легко решать треугольные системы. Затем опишем приведение системы общего вида к треугольной форме при помощи преобразований Гаусса. И, наконец, учитывая то, что полученный метод ведет себя очень плохо на нетривиальном классе задач, рассмотрим концепцию выбора ведущих элементов.

**Треугольные системы.** Рассмотрим следующую треугольную  $2 \times 2$ -систему:

$$\begin{bmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

Если  $l_{11}, l_{22} \neq 0$ , то неизвестные могут быть определены последовательно:

$$\begin{cases} x_1 = b_1/l_{11}, \\ x_2 = (b_2 - l_{21}x_1)/l_{22} \end{cases}$$

Это  $2 \times 2$ -версия алгоритма, известного как *прямая подстановка*. Общую процедуру получаем, разрешая  $i$ -е уравнение системы  $Lx = b$  относительно  $x_i$ :

$$x_i = \left( b_i - \sum_{j=1}^{i-1} l_{ij}x_j \right) / l_{ii}.$$

Если вычисления выполнить для  $i$  от 1 до  $n$ , то будут получены все компоненты вектора  $x$ . Заметим, что на  $i$ -м шаге необходимо скалярное произведение векторов  $L(i, 1 : i - 1)$  и  $x(1 : i - 1)$ . Так как  $b_i$  содержится только в формуле для  $x_i$ , мы можем записать  $x_i$  на месте  $b_i$ .

#### Прямая подстановка.

Предположим, что  $L \in \mathbb{R}^{n \times n}$  — нижняя треугольная матрица и  $b \in \mathbb{R}^n$ . Следующий код Python заменяет  $b$  на решение системы  $Lx = b$ . Матрица  $L$  должна быть невырождена.

---

```
b[0] = b[0]/L[0,0]
for i in range(1, len(b)):
    b[i] = (b[i] - np.dot(L[i, :i], b[:i]))/L[i,i]
```

---

Аналогичный алгоритм для верхней треугольной системы  $Ux = b$  называется *обратная подстановка*. Вот формула для  $x_i$ :

$$x_i = \left( b_i - \sum_{j=i+1}^n u_{ij}x_j \right) / u_{ii}.$$

и снова  $x_i$  можно записать на месте  $b_i$ .

#### Обратная подстановка.

Если матрица  $U \in \mathbb{R}^{n \times n}$  верхняя треугольная и  $b \in \mathbb{R}^n$ , то следующий код Python заменяет  $b$  на решение системы  $Ux = b$ . Матрица  $U$  должна быть невырождена.

---

```
b[-1] = b[-1]/U[-1,-1]
for i in range(len(b)-2, -1, -1):
    b[i] = (b[i] - np.dot(U[i,i+1:], b[i+1:]))/U[i,i]
```

---

Отметим, что при реализации формул прямой и обратной подстановки мы использовали срезы массивов (см. раздел ??). В первом алгоритме  $L[i, :i]$  означает, что берется из строки двумерного массива с индексом  $i$  все элементы с нулевого до  $i-1$ -го включительно, а  $b[:i]$  — элементы массива  $b$  с индексами от 0 до  $i-1$  включительно. Во втором алгоритме используются срезы  $U[i, i+1:]$ , содержащий от  $i+1$ -го до последнего (включительно) элементы  $i$ -той строки, и  $b[i+1:]$  с элементами от  $i+1$ -го до по-

следнего (включительно). Кроме того использовалась функция `dot` модуля `numpy`, которая вычисляет скалярное произведение двух векторов. Таким образом, мы здесь использовали векторизованные вычисления.

**LU-разложение.** Как мы только что видели, треугольные системы решаются «легко». Идея метода Гаусса — это преобразование системы (1) в эквивалентную треугольную систему. Преобразование достигается соответствующих линейных комбинаций уравнений. Например, в системе

$$\begin{aligned} 3x_1 + 5x_2 &= 9, \\ 6x_1 + 7x_2 &= 4, \end{aligned}$$

умножая ее первую строку на 2 и вычитая ее из второй части, мы получим

$$\begin{aligned} 3x_1 + 5x_2 &= 9, \\ -3x_2 &= -14. \end{aligned}$$

Это и есть метод исключений Гаусса при  $n = 2$ . Дадим полное описание этой важной процедуры, причем опишем ее выполнение на языке матричных разложений. Данный пример показывает, что алгоритм вычисляет нижнюю треугольную матрицу  $L$  и верхнюю треугольную матрицу  $U$  так, что  $A = LU$ , т.е.

$$\begin{bmatrix} 3 & 5 \\ 6 & 7 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 3 & 5 \\ 0 & -3 \end{bmatrix}$$

Решение исходной задачи  $Ax = b$  находится посредством последовательного решения двух треугольных систем:

$$Ly = b, \quad Ux = y \quad \Rightarrow \quad Ax = LUx = Ly = b$$

**Матрица преобразования Гаусса.** Чтобы получить разложение, описывающее исключение Гаусса, нам нужно иметь некоторое матричное описание процесса обнуления матрицы. Пусть  $n = 2$ , тогда как  $x_1 \neq 0$  и  $\tau = x_2/x_1$ , то

$$\begin{bmatrix} 1 & 0 \\ -\tau & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ 0 \end{bmatrix}$$

В общем случае предположим, что  $x \in \mathbb{R}^n$  и  $x_k \neq 0$ . Если

$$\tau^{(k)T} = [0, \dots, 0, \underbrace{\tau_{k+1}, \dots, \tau_n}_k], \quad \tau_i = \frac{x_i}{x_k} \quad i = k+1, k+2, \dots, n$$

и мы обозначим

$$M_k = I - \tau^{(k)} e_k^T, \quad (2)$$

где

$$e_k^T = [\underbrace{0, \dots, 0}_{k-1}, 1, \underbrace{0, \dots, 0}_{n-k}],$$

$$I = [e_1, e_2, \dots, e_n]$$

то

$$M_k x = \begin{bmatrix} 1 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 1 & 0 & \dots & 0 \\ 0 & \dots & -\tau_{k+1} & 1 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & -\tau_n & 0 & \dots & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ x_{k+1} \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Матрица  $M_k$  — это матрица *преобразования Гаусса*. Она является нижней унитреугольной. Компоненты  $\tau_{k+1}, \tau_{k+2}, \dots, \tau_n$  — это *множители Гаусса*. Вектор  $\tau^{(k)}$  называется *вектором Гаусса*.

Для реализации данных идей имеется функция, которая вычисляет вектор множителей. Если  $x$  — массив из  $n$  элементов и  $x[0]$  ненулевой, функция `gauss` возвращает вектор длины  $n - 1$ , такой, что если  $M$  — матрица преобразования Гаусса, причем  $M[1:, 1] = -\text{gauss}(x)$  и  $y = \text{dot}(M, x)$ , то  $y[1:] = 0$ :

---

```
def gauss(x):
    x = np.array(x, float)
    return x[1:]/x[0]
```

---

**Применение матриц преобразования Гаусса.** Умножение на матрицу преобразования Гаусса выполняется достаточно просто. Если матрица  $C \in \mathbb{R}^{n \times r}$  и  $M_k = I - \tau^{(k)} e_k^T$ , тогда преобразование вида

$$M_k C = (I - \tau^{(k)} e_k^T) C = C - \tau^{(k)} (e_k^T C)$$

осуществляет одноранговую модификацию. Кроме того, поскольку элементы вектора  $\tau^{(k)}$  равны нулю от первого до  $k$ -го равны нулю, то в каждой  $k$ -ой строке матрицы  $C$  задействованы лишь элементы, начиная с  $k + 1$ -го. Следовательно, если “ $C$ ” — двумерный массив, задающий матрицу  $C$ , и “ $M$ ” задает  $n \times n$ -преобразование Гаусса  $M_1$ , причем “ $M[1:, 1] = -t$ ”, “ $t$ ” — множитель Гаусса, соответствующий  $\tau^{(1)T}$ , тогда следующая функция заменяет  $C$  на  $M_1 C$ :

---

```
def gauss_app(C, t):
    C = np.array(C, float)
```

---

---

```

t = np.array([[t[i]] for i in range(len(t))], float)
C[1:, :] = C[1:, :] - t*C[0, :]
return C

```

---

Отметим, что если матрица  $M[k+1:, k] = -t$ , тогда обращение вида  $C[k:, :] = \text{gauss\_app}(C[k:, :], t)$  заменяет  $C$  на  $M_k C$

Матрицы преобразования Гаусса  $M_1, M_2, \dots, M_{n-1}$ , как правило, можно подобрать так, что матрица  $M_{n-1} M_{n-2} \dots M_1 A = U$  является верхней треугольной. Легко убедиться, что если  $M_k = I - \tau^{(k)} e_k^T$ , тогда обратная к ней задается следующим выражением  $M_k^{-1} = I + \tau^{(k)} e_k^T$  и поэтому

$$A = LU, \quad (3)$$

где

$$L = M_1^{-1} M_2^{-1} \dots M_{n-1}^{-1}.$$

Очевидно, что  $L$  — это нижняя унитреугольная матрица. Разложение (3) называется *LU-разложением* матрицы  $A$ . Необходимо проверять *ведущие элементы* матрицы  $A$  ( $a_{kk}$ ) на нуль, чтобы избежать деления на нуль в функции `gauss`. Это говорит о том, что *LU-разложение* может не существовать. Известно, что *LU-разложение* матрицы  $A$  существует, если главные миноры матрицы  $A$  не равны нулю при этом оно единственно и  $\det A = u_{11} u_{22} \dots u_{nn}$ .

**Реализация.** Рассмотрим пример при  $n = 3$ :

---

```

In [1]: import numpy as np

In [2]: A = np.array([[1, 4, 7], [2, 5, 8], [3, 6, 10]])

In [3]: A
Out[3]:
array([[ 1,  4,  7],
       [ 2,  5,  8],
       [ 3,  6, 10]])

In [4]: M1 = np.array([[1, 0, 0], [-2, 1, 0], [-3, 0, 1]])

In [5]: M1
Out[5]:
array([[ 1,  0,  0],
       [-2,  1,  0],
       [-3,  0,  1]])

In [6]: np.dot(M1, A)
Out[6]:
array([[ 1,  4,  7],
       [ 0, -3, -6],
       [ 0, -6, -11]])

In [7]: M2 = np.array([[1, 0, 0], [0, 1, 0], [0, -2, 1]])

```

```

In [8]: M2
Out[8]:
array([[ 1,  0,  0],
       [ 0,  1,  0],
       [ 0, -2,  1]])

In [9]: np.dot(M2, np.dot(M1, A))
Out[9]:
array([[ 1,  4,  7],
       [ 0, -3, -6],
       [ 0,  0,  1]])

```

#### Функция `numpy.dot`.

Обратите внимание, что в приведенном примере мы использовали функцию `dot` модуля `numpy`, которая выполняет умножение матриц в "правильном смысле", в то время как выражение `M1*A` производит поэлементное умножение.

Обобщение этого примера позволяет представить  $k$ -й шаг следующим образом:

- Мы имеем дело с матрицей  $A^{(k-1)} = M_{k-1} \cdots M_1 A$ , которая с 1-го по  $(k-1)$ -й столбец является верхней треугольной.
- Поскольку мы уже получили нули в столбцах с 1-го по  $(k-1)$ -й, то преобразование Гаусса можно применять только к столбцам с  $k$ -го до  $n$ -го. На самом деле нет необходимости применять преобразование Гаусса также и  $k$ -му столбцу, так как мы знаем результат.
- Множители Гаусса, задающие матрицу  $M_k$  получаются по матрице  $A(k : n, k)$  и могут храниться в позициях, в которых получены нули.

С учетом сказанного выше мы можем написать следующую функцию:

```

def lu(A):
    LU = np.array(A, float)
    for k in range(LU.shape[0]-1):
        t = gauss(LU[k:, k])
        LU[k+1:, k] = t
        LU[k:, k+1:] = gauss_app(LU[k:, k+1:], t)

    return LU

```

Эта функция возвращает  $LU$ -разложение матрицы  $A$ . Где же храниться матрица  $L$ ? Дело в том, что если  $L = M_1^{-1}M_2^{-1}\dots M_{n-1}^{-1}$ , то элементы с  $(k+1)$ -го до  $n$ -го в  $k$ -том столбце матрицы  $L$  равны множителям Гаусса  $\tau_{k+1}, \tau_{k+2}, \dots, \tau_n$  соответственно. Этот факт очевиден, если посмотреть на произведение, задающее матрицу  $L$ :

$$L = (I + \tau^{(1)}e_1^T \dots (I + \tau^{(n-1)}e_{n-1}^T)) = I + \sum_{k=1}^{n-1} \tau^{(k)}e_k^T.$$

Поэтому элементы  $l_{ik} = lu_{ik}$  для всех  $i > k$ . Здесь  $lu_{ik}$  — элементы матрицы возвращаемой функцией `lu`.

После разложения матрицы  $A$  с помощью функции `lu` в возвращаемом массиве будут храниться матрицы  $L$  и  $U$ . Поэтому мы можем решить систему  $Ax = b$ , используя прямую и обратную подстановки описанные в разделе 1.1:

---

```
def solve_lu(A, b):
    LU = lu(A)
    b = np.array(b, float)
    for i in range(1, len(b)):
        b[i] = b[i] - np.dot(LU[i, :i], b[:i])
    for i in range(len(b)-1, -1, -1):
        b[i] = (b[i] - np.dot(LU[i, i+1:], b[i+1:]))/LU[i, i]
    return b

def inverse(A):
    E = np.eye(A.shape[0])
    Inv = []
    for e in E:
        x = solve_lu(A, e)
        Inv.append(x)
    return np.array(Inv)
```

---

#### Замечание.

Отметим, что во всех представленных функциях мы выполняли явное преобразование входных параметров в массивы NumPy с элементами типа `float`. Это позволит правильно работать функциям в случае, если мы по ошибке создадим входные параметры не как массивы, а как списки.

**Тестирование.** Как известно метод Гаусса является прямым, т.е. дает точное решение системы линейных уравнений. Для проверки реализации решения системы линейных уравнений методом Гаусса мы можем написать следующую функцию:



---

```
def test_solve_lu():
    A = np.array([[1, 4, 7], [2, 5, 8], [3, 6, 10]])
    expected = np.array([-1./3, 1./3, 0])
    b = np.dot(A, expected)
    computed = solve_lu(A, b)
    tol = 1e-14
    success = np.linalg.norm(computed - expected) < tol
    msg = 'x_exact = ' + str(expected) + '; x_computed = ' + str(computed)
    assert success, msg
```

---

### Замечание.

Здесь мы задали матрицу  $A$  системы и точное решение  $\text{expected}$ , на основе которых получили вектор правой части  $b = \text{np.dot}(A, x)$ . Для сравнения численного решения с точным используется функция `np.linalg.norm`. В случае вызова с одним аргументом вычисляется  $l_2$ -норма:  $\|v\|_2 = \sqrt{\sum_{i=1}^n v_i^2}$ .

**Выбор ведущего элемента.** Как уже упоминалось,  $LU$ -разложение может не существовать. В методе Гаусса с выбором ведущего элемента на очередном шаге исключается неизвестное, при котором коэффициент по модулю является наибольшим. В этом случае метод Гаусса применим для любых невырожденных матриц ( $\det A \neq 0$ ).

Такая стратегия предполагает переупорядочивание данных в виде перестановки двух матричных строк. Для этого используются понятие перестановочной матрицы. *Перестановочная матрица* (или *матрица перестановок*) — это матрица, отличающаяся от единичной лишь перестановкой строк, например

$$P = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}.$$

Перестановочную матрицу нет необходимости хранить полностью. Гораздо более эффективно перестановочную матрицу можно представить в виде целочисленного вектора  $p$  длины  $n$ . Один из возможных способов такого представления — это держать в  $p_k$  индекс столбца в  $k$ -й строке, содержащий единственный элемент равный 1. Так вектор  $p = [4, 1, 3, 2]$  соответствует кодировке приведенной выше матрицы  $P$ . Также возможно закодировать  $P$  указанием индекса строки в  $k$ -ом столбце, содержащего 1, например,  $p = [2, 4, 3, 1]$ .

Если  $P$  — это матрица перестановок, а  $A$  — некоторая матрица, тогда матрица  $AP$  является вариантом матрицы  $A$  с переставленными столбцами, а  $PA$  — вариантом матрицы  $A$  с переставленными строками.

Перестановочные матрицы ортогональны, и поэтому если  $P$  — перестановочная матрица, то  $P^{-1} = P^T$ .

В этом разделе особый интерес представляют *взаимные перестановки*. Такие перестановки осуществляют матрицы, получаемые простой переменой мест двух строк единичной матрицы, например

$$E = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}.$$

Взаимные перестановки могут использоваться для описания перестановок строк и столбцов матрицы. В приведенном примере порядка  $4 \times 4$  матрица  $EA$  отличается от матрицы  $A$  перестановкой 1-й и 4-й строк. Аналогично матрица  $AE$  отличается от матрицы  $A$  перестановкой 1-го и 4-го столбцов.

Если  $P = E_n E_{n-1} \cdots E_1$  и каждая матрица  $E_k$  является единичной с переставленными  $k$ -й и  $p_k$ -й строками, то вектор  $p = [p_1, p_2, \dots, p_n]$  содержит всю необходимую информацию о матрице  $P$ . Действительно, вектор  $x$  может быть замещен на вектор  $Px$  следующим образом:

**for**  $k = 1 : n$

$$x_k \leftrightarrow x_{p_k}$$

Здесь символ  $\leftrightarrow$  обозначает «выполнение перестановки»:

$$x_k \leftrightarrow x_{p_k} \Leftrightarrow r = x_k, x_k = x_{p_k}, x_{p_k} = r.$$

Поскольку каждая матрица  $E_k$  является симметричной и  $P^T = E_1 E_2 \cdots E_n$ , то также можно выполнить замещение вектора  $x$  на вектор  $P^T x$ :

**for**  $k = n : 1 : -1$

$$x_k \leftrightarrow x_{p_k}$$

Существуют разные стратегии выбора ведущего элемента. Мы остановимся на стратегии частичного выбора. Пусть матрица

$$A = \begin{bmatrix} 3 & 17 & 10 \\ 2 & 4 & -2 \\ 6 & 18 & -12 \end{bmatrix}.$$

Чтобы добиться наименьших множителей в первой матрице разложения по Гауссу с помощью взаимных перестановок строк, надо сделать элемент  $a_{11}$  наибольшим в первом столбце. Если  $E_1$  — матрица взаимных перестановок, тогда

$$E_1 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}.$$

Поэтому

$$E_1 A = \begin{bmatrix} 6 & 18 & -12 \\ 2 & 4 & -2 \\ 3 & 17 & 10 \end{bmatrix}$$

и

$$M_1 = \begin{bmatrix} 1 & 0 & 0 \\ -1/3 & 1 & 0 \\ -1/2 & 0 & 1 \end{bmatrix} \Rightarrow M_1 E_1 A = \begin{bmatrix} 6 & 18 & -12 \\ 0 & -2 & 2 \\ 0 & 8 & 16 \end{bmatrix}.$$

Теперь, чтобы получить наименьший множитель в матрице  $M_2$ , необходимо переставить 2-ю и 3-ю строки и т.д.

Пример иллюстрирует общую идею, основанную на перестановке строк. Обобщая эту идею, получим следующий алгоритм:

#### **LU-разложение с частичным выбором.**

Если матрица  $E \in \mathbb{R}^{n \times n}$ , то данный алгоритм вычисляет матрицы преобразования Гаусса  $M_1, M_2, \dots, M_{n-1}$  и матрицы взаимных перестановок  $E_1, E_2, \dots, E_{n-1}$ , такие что матрица  $M_{n-1} E_{n-1} \dots M_1 E_1 A = U$  является верхней треугольной. При этом нет множителей, превосходящих 1 по абсолютной величине. Подматрица  $[a_{ik}]_{i=1}^k$  замещается на матрицу  $[u_{ik}]_{i=1}^k$ ,  $k = 1, 2, \dots, n$ . Подматрица  $[a_{ik}]_{i=k+1}^n$  замещается на матрицу  $[m_{k;ik}]_{i=k+1}^n$ ,  $k = 1, 2, \dots, n-1$ . Целочисленный вектор  $piv$  размера  $n-1$  задает взаимные перестановки. В частности, матрица  $E_k$  переставляет строки  $k$  и  $piv_k$ ,  $k = 1, 2, \dots, n-1$ .

**for**  $k = 1 : n$

1. Зададим  $\mu$ , такое что  $k \leq \mu \leq n$  и  $|a_{\mu k}| = \max_{k \leq i \leq n} |a_{ik}|$

2.  $a_{k,k:n} \leftrightarrow a_{\mu,k:n}$ ;  $piv_k = \mu$

**if**  $a_{kk} \neq 0$

$t = \text{gauss}(A_{k:n,k}); A_{k+1:n,k} = t$

$A_{k:n,k+1:n} = \text{gauss\_app}(A_{k:n,k+1:n}, t)$

**end if**

**end for**

Чтобы решить линейную систему  $Ax = b$  после вызова последнего алгоритма, мы должны

1. Вычислить вектор  $y = M_{n-1}E_{n-1} \cdots M_1E_1b$ . 2. Решить верхнюю треугольную систему  $Ux = y$ .

## 1.2. Методы решения систем с симметричными матрицами

Здесь мы опишем методы, использующие специфику при решении задачи  $Ax = b$ . В случае, когда  $A$  — симметричная невырожденная матрица, т.е.  $A = A^T$  и  $\det(A) \neq 0$ , существует разложение вида

$$A = LDL^T, \quad (4)$$

где  $L$  — нижняя унитреугольная матрица,  $D$  — диагональная матрица. В связи с этим работа связанная с получением разложения :eq:sles-ldl, составляет половину от того, что требуется для исключения Гаусса. Когда разложение :eq:sles-ldl получено, решение системы  $Ax = b$  может быть найдено посредством решения систем  $Ly = b$  (прямая подстановка),  $Dz = y$  и  $L^T x = z$ .

**$LDL^T$ -разложение.** Разложение (4) может быть найдено при помощи исключения Гаусса, вычисляющего  $A = LU$ , с последующим определением  $D$  из уравнения  $U = DL^T$ . Тем не менее можно использовать интересный альтернативный алгоритм непосредственного вычисления  $L$  и  $D$ .

Допустим, что мы знаем первые  $j-1$  столбцов матрицы  $L$ , диагональные элементы  $d_1, d_2, \dots, d_{j-1}$  матрицы  $D$  для некоторого  $j$ ,  $1 \leq j \leq n$ . Чтобы получить способ вычисления  $l_{ij}$ ,  $i = j+1, j+2, \dots, n$ , и  $d_j$  приравняем  $j$ -е столбцы в уравнении  $A = LDL^T$ . В частности,

$$A(1:j, j) = Lv, \quad (5)$$

где

$$v = DL^T e_j = \begin{bmatrix} d_1 l_{j1} \\ \vdots \\ d_{j-1} l_{jj-1} \\ d_j \end{bmatrix}.$$

Следовательно, компоненты  $v_k$ ,  $k = 1, 2, \dots, j-1$  вектора  $v$  могут быть получены простым масштабированием элементов  $j$ -й строки матрицы  $L$ . Формула для  $j$ -й компоненты вектора  $v$  получается из  $j$ -го уравнения системы  $L(1:j, 1:j)v = A(1:j, j)$ :

$$v_j = a_{jj} - \sum_{k=1}^{j-1} l_{jk} v_k,$$

Когда мы знаем  $v$ , мы вычисляем  $d_j = v_j$ . «Нижняя» половина формулы (5) дает уравнение

$$L(j+1:n, 1:j)v(1:j) = A(j+1:n, j),$$

откуда для вычисления  $j$ -го столбца матрицы  $L$  имеем:

$$L(j+1:n, j) = (A(j+1:n, j) - L(j+1:n, 1:j-1)v(1:j-1))/v_j.$$

**Реализация.** Для получения  $LDL^T$ -разложения матрицы  $A$  можем написать функцию (сценарий `ld.py`):

---

```
def ld(A):
    """
    Для симметричной матрицы A вычисляет нижнюю треугольную
    матрицу L и диагональную матрицу D, такие
    что A = LDL^T. Элементы a_{ij} замещаются на L_{ij}, если i > j,
    и на d_i, если i = j
    """
    n = len(A)
    LD = np.array(A, float)
    for j in range(n):
        v = np.zeros(j+1)
        v[:j] = LD[j,:j]*LD[range(j),range(j)]
        v[j] = LD[j,j] - np.dot(LD[j,:j],v[:j])
        LD[j,j] = v[j]
        LD[j+1:,j] = (LD[j+1:,j] - np.dot(LD[j+1:,:j],v[:j]))/v[j]

    return LD
```

---

В этой реализации мы использовали векторизованные вычисления. Разберем некоторые выражения. Строка

---

```
v[:j] = LD[j,:j]*LD[range(j),range(j)]
```

---

можно заменить следующим циклом:

---

```
for i in range(j):
    v[i] = LD[j,i]*LD[i,i]
```

---

В нашей программе доступ к  $j$  диагональным элементам массива  $A$  осуществляется выражением  $A[\text{range}(j), \text{range}(j)]$ .

При вычислении  $v[j]$  использовалась функция `np.dot`, которая вычисляет скалярное произведение векторов.

Отметим также строку

---

```
LD[j+1:,j] = (LD[j+1:,j] - np.dot(LD[j+1:,:j],v[:j]))/v[j]
```

---

в которой используется срез  $L[j+1:, j]$ , т.е. элементы с  $j+1$ -го до последнего в  $j$ -ом столбце.

Для решения системы  $Ax = b'$  с использованием  $LDL^T$ -разложения можно написать следующую функцию

---

```
def ld_solve(A, b):
    """
    Решает систему  $Ax = b$  с использованием  $LDL^T$ -разложения
    """
    LD = ld(A)
    b = np.array(b, float)
    for i in range(1, len(b)):
        b[i] = b[i] - np.dot(LD[i, :i], b[:i])
    b[:] = b[:] / LD[range(len(b)), range(len(b))]
    for i in range(len(b)-1, -1, -1):
        b[i] = (b[i] - np.dot(LD[i+1:, i], b[i+1:]))
    return b
```

---

**Разложение Холецкого.** Известно, что в случае симметричной положительно определенной матрицы разложение (4) существует и устойчиво. Тем не менее в этом случае можно использовать другое разложение:

$$A = GG^T \quad (6)$$

известное как *разложение Холецкого*, а матрицы  $G$  называются *треугольниками Холецкого*.

Это легко показать, исходя из существования  $LDL^T$  разложения. Так как для симметричной положительно определенной матрицы существует  $A = LDL^T$  и диагональные элементы матрицы  $D$  положительны, то  $G = L \text{diag}(\sqrt{d_{11}}, \sqrt{d_{22}}, \dots, \sqrt{d_{nn}})$ .

## 2. Итерационные методы решения систем линейных алгебраических уравнений

### 2.1. Стандартные итерационные методы

В разделах 1.1 и 1.2 процедуры решения систем алгебраических уравнений были связаны с разложением матрицы коэффициентов  $A$ . Методы такого типа называются *прямыми методами*. Противоположностью прямым методам являются *итерационные методы*. Эти методы порождают последовательность приближенных решений  $\{x^{(k)}\}$ . При оценивании качества итерационных методов в центре внимания вопрос от том, как быстро сходятся итерации  $x^{(k)}$ .

**Итерации Якоби и Гаусса — Зейделя.** Простейшей итерационной схемой, возможно, являются *итерации Якоби*. Они определяются для матриц с ненулевыми диагональными элементами. Идею метода можно представить, используя запись  $3 \times 3$ -системы  $Ax = b$  в следующем виде:

$$\begin{aligned}x_1 &= (b_1 - a_{12}x_2 - a_{13}x_3)/a_{11}, \\x_2 &= (b_2 - a_{21}x_1 - a_{23}x_3)/a_{22}, \\x_3 &= (b_3 - a_{31}x_1 - a_{32}x_2)/a_{33}.\end{aligned}$$

Предположим, что  $x^{(k)}$  — какое-то приближение к  $x = A^{-1}b$ . Чтобы получить новое приближение  $x^{(k+1)}$ , естественно взять:

$$\begin{aligned}x_1^{(k+1)} &= (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)})/a_{11}, \\x_2^{(k+1)} &= (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)})/a_{22}, \\x_3^{(k+1)} &= (b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)})/a_{33}.\end{aligned}$$

Эти формулы и определяют итерации Якоби в случае  $n = 3$ . Для произвольных  $n$  мы имеем

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}, \quad i = 1, 2, \dots, n. \quad (7)$$

Заметим, что в итерациях Якоби при вычислении  $x_i^{(k+1)}$  не используется информация, полученная в самый последний момент. Например, при вычислении  $x_2^{(k+1)}$  используется  $x_1^{(k)}$ , хотя уже известна компонента  $x_1^{(k+1)}$ . Если мы пересмотрим итерации Якоби с тем, чтобы всегда использовать самые последние оценки для  $x_i$ , то получим:

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}, \quad i = 1, 2, \dots, n. \quad (8)$$

Так определяется то, что называется *итерациями Гаусса — Зейделя*.

Для итераций Якоби и Гаусса — Зейделя переход от  $x^{(k)}$  к  $x^{(k+1)}$  в сжатой форме описывается в терминах матриц  $L$ ,  $D$  и  $U$ , опреде-

ляемых следующим образом:

$$L = \begin{bmatrix} 0 & 0 & \cdots & \cdots & 0 \\ a_{21} & 0 & \cdots & \cdots & 0 \\ a_{31} & a_{32} & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn-1} & 0 \end{bmatrix},$$

$$D = \text{diag}(a_{11}, a_{12}, \dots, a_{nn}),$$

$$U = \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & 0 & a_{23} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & a_{n-1n} \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix}.$$

Шаг Якоби имеет вид  $M_J x^{(k+1)} = N_J x^{(k)} + b$ , где  $M_J = D$  и  $N_J = -(L + U)$ . С другой стороны, шаг Гаусса — Зейделя определяется как  $M_G x^{(k+1)} = N_G x^{(k)} + b$ , где  $M_G = (D + L)$  и  $N_G = -U$ .

Процедуры Якоби и Гаусса — Зейделя — это типичные представители большого семейства итерационных методов, имеющих вид

$$Mx^{(k+1)} = Nx^{(k)} + b, \quad (9)$$

где  $A = M - N$  — расщепление матрицы  $A$ . Для практического применения итераций (9) должна «легко» решаться система с матрицей  $M$ . Заметим, что для итераций Якоби и Гаусса — Зейделя матрица  $M$  соответственно диагональная и нижняя треугольная.

Сходятся ли итерации (9) к  $x = A^{-1}b$ , зависит от собственных значений матрицы  $M^{-1}N$ . Определим *спектральный радиус* произвольной  $n \times n$ -матрицы  $G$  как

$$\rho(G) = \max\{|\lambda| : \lambda \in \lambda(G)\},$$

тогда если матрица  $M$  невырожденная и  $\rho(M^{-1}N) < 1$ , то итерации  $x^{(k)}$ , определенные согласно  $Mx^{(k+1)} = Nx^{(k)} + b$ , сходятся к  $x = A^{-1}b$  при любом начальном векторе  $x^{(0)}$ .

**Последовательная верхняя релаксация.** Метод Гаусса — Зейделя очень привлекателен в силу своей простоты. К несчастью, если спектральный радиус для  $M_G^{-1}N_G$  близок к единице, то метод может оказаться непозволительно медленным из-за того, что ошибки стремятся к нулю как  $\rho(M_G^{-1}N_G)^k$ . Чтобы исправить это,



возьмем  $\omega \in \mathbb{R}$  и рассмотрим следующую модификацию шага Гаусса — Зейделя:

$$x_i^{(k+1)} = \omega \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) / a_{ii} + (1 - \omega) x_i^{(k)}. \quad (10)$$

Так определяется метод *последовательной верхней релаксации* (SOR — Successive Over Relaxation). В матричных обозначениях шаг SOR выглядит как

$$M_\omega x^{(k+1)} = N_\omega x^{(k)} + \omega b,$$

где  $M_\omega = D + \omega L$  и  $N_\omega = (1 - \omega)D - \omega U$ . Для небольшого числа специфических задач значения реалксационного параметра  $\omega$ , минимизирующего  $\rho(M_\omega^{-1} N_\omega)$ , является известным. В более сложных задачах, однако, для того чтобы определить подходящее  $\omega$ , может возникнуть необходимость в выполнении весьма трудного анализа собственных значений.

## 2.2. Метод сопряженных градиентов

Трудность, связанная с SOR и такого же типа методами, заключается в том, что они зависят от параметров, правильный выбор которых иногда бывает затруднителен. Например, для того чтобы чебышевское ускорение было успешным, нам нужны хорошие оценки для наибольшего и наименьшего собственных значений соответствующей итерационной матрицы  $^{-1}N$ . Если эта матрица не устроена по-особому, то получение их в аналитическом виде, скорее всего, невозможно, а вычисление дорого.

**Наискорейший спуск.** Вывод метода связан с минимизацией функционала:

$$\varphi(x) = \frac{1}{2} x^T A x - x^T b,$$

где  $b \in \mathbb{R}^n$  и матрица  $A$  предполагается положительно определенной и симметричной. Минимальное значение  $\varphi$  равно  $-b^T A^{-1} b / 2$  и достигается при  $x = A^{-1} b$ . Таким образом, минимизация  $\varphi$  и решение системы  $Ax = b$  — эквивалентные задачи.

Одной из самых простых стратегий минимизации функционала  $\varphi$  является *метод наискорейшего спуска*. В текущей точке  $x_c$  функция  $\varphi$  убывает наиболее быстро в направлении антиградиента  $\nabla \varphi(x_c) = b - Ax_c$ . Мы называем  $r_c = b - Ax_c$  *невязкой* вектора  $x_c$ . Если невязка ненулевая, то  $\varphi(x_c + \alpha r_c) < \varphi(x_c)$  для некоторого положительного  $\alpha$  (будем называть этот параметр *поправкой*). В

методе наискорейшего спуска (с точной минимизацией на прямой) мы берем поправку

$$\alpha = \frac{r_c^T r_c}{r_c^T A r_c},$$

дающую минимум для  $\varphi(x_c + \alpha r_c)$ . Итерационный процесс запишется следующим образом

$$\alpha_k = \frac{r_{k-1}^T r_{k-1}}{r_{k-1}^T A r_{k-1}},$$

$$x_k = x_{k-1} + \alpha_k r_{k-1},$$

$$r_k = b - A x_k, \quad k = 1, 2, \dots$$

при начальных векторах  $x_0 = 0$ ,  $r_0 = b$ .

К несчастью, скорость сходимости может быть недопустимо медленной, если число обусловленности  $\kappa(A) = \lambda_1(A)/\lambda_2(A)$  большое. В этом случае линии уровня для  $\varphi$  являются сильно вытянутыми гиперэллипсоидами, а минимизация соответствует поиску самой нижней точки на относительно плоском дне крутого оврага. При наискорейшем спуске мы вынуждены переходить с одной стороны оврага на другую вместо того, чтобы спуститься к его дну. Направления градиента, возникающие при итерациях, являются слишком близкими; это и замедляет продвижение к точке минимума.

**Произвольные направления спуска.** Чтобы избежать ловушек при наискорейшем спуске, мы рассмотрим последовательную минимизацию  $\varphi$  вдоль какого-либо множества направлений  $\{p_1, p_2, \dots\}$ , которые не обязаны соответствовать невязкам  $\{r_0, r_1, \dots\}$ . Легко показать, что минимум  $\varphi(x_{k-1} + \alpha p_k)$  по  $\alpha$  дает

$$\alpha_k = \frac{p_k^T r_{k-1}}{p_k^T A p_k}.$$

Для того, чтобы обеспечить уменьшение функционала  $\varphi$ , мы должны потребовать, чтобы  $p_k$  не был ортогонален к  $r_{k-1}$ . Проблема состоит в том, как выбирать эти векторы, чтобы гарантировать глобальную сходимость и в то же время обойти ловушки наискорейшего спуска.

**Метод сопряженных градиентов.** Как было сказано выше направления спуска  $p_k$  нужно выбирать так, чтобы они не были ортогональны к невязкам  $r_{k-1}$ , т.е.  $p_k^T r_{k-1} \neq 0$ . Кроме того, метод сопряженных градиентов основан на том, что требуется, чтобы направление  $p_k$  было  $A$ -сопряженным по отношению к  $p_1, p_2, \dots, p_{k-1}$ , т.е.  $p_m^T A p_k = 0$  для  $m = 1, 2, \dots, k-1$ .

Поскольку наша цель — осуществить быстрое сокращение величины невязок, естественно выбирать в качестве  $p_k$  вектор, который ближе всего к  $r_{k-1}$  среди векторов,  $A$ -сопряженных с  $p_1, p_2, \dots, p_{k-1}$ .

Для получения таких направлений спуска и нахождения приближенного решения используется *метод сопряженных градиентов*. Ниже представлен код функции, реализующий данный алгоритм (файл [cg.py](#))

---

```
def cg(A, b, tol, it_max):
    it = 0
    x = 0
    r = np.copy(b)
    r_prev = np.copy(b)
    rho = np.dot(r, r)
    p = np.copy(r)
    while (np.sqrt(rho) > tol*np.sqrt(np.dot(b, b))) and it < it_max:
        it += 1
        if it == 1:
            p[:] = r[:]
        else:
            beta = np.dot(r, r)/np.dot(r_prev, r_prev)
            p = r + beta*p
            w = np.dot(A, p)
            alpha = np.dot(r, r)/np.dot(p, w)
            x = x + alpha*p
            r_prev[:] = r[:]
            r = r - alpha*w
            rho = np.dot(r, r)
    return x, it
```

---

### 3. Тестирование реализации методов

#### 4. Задачи

##### Задача 1: Решение системы линейных уравнений с трехдиагональной матрицей

Написать программу, которая решает систему линейных уравнений для трехдиагональной ( $a_{ij} = 0$  при  $|i - j| > 1$ )  $n \times n$ -матрицы на основе  $LU$ -разложения. Написать следующие тестовые функции:

1. Найти решение уравнения с

$$a_{ii} = 2, \quad a_{ii-1} = a_{ii+1} = -1$$

при правой части  $b_i = 2h^2$ ,  $h = 1/n$ ,  $i = 1, 2, \dots, n-1$ ,  $b_n = -(n-1) * h(1 - (n-1)/h)$  и сравнить его с точным решением  $x_i = ih(1 - ih)$ ,  $i = 1, 2, \dots, n$ .

2. Вычислить определитель матрицы и сравнить его значение с точным  $n + 1$ .

**Подсказка.** Трехдиагональная матрица  $A$  задается тремя диагоналями:

$$d_i = a_{ii}, \quad e_i^u = a_{ii+1}, \quad e_i^l = a_{ii-1}.$$

В модуле функция (например, `lu3`) выполняет  $LU$ -разложение матрицы  $A$  и возвращает результат в виде трех диагоналей. Для решения системы используется другая функция (например, `solve_lu3`).

## Задача 2: Метод Гаусса с частичным выбором ведущего элемента

Написать модуль, который реализует идеи частичного выбора ведущего элемента из раздела 1.1. Функция для  $LU$ -разложения должна выводить, кроме самого разложения, еще и вектор, определяющий матрицу перестановок. Напишите тестовые функции для проверки выполнения  $LU$ -разложения и решения системы уравнений с матрицей

$$A = \begin{bmatrix} 3 & 17 & 10 \\ 2 & 4 & -2 \\ 6 & 18 & -12 \end{bmatrix}$$

## Задача 3: Разложение Холецкого

Написать программу, реализующую разложение Холецкого  $A = GG^T$  для симметричной положительно определенной матрицы  $A$  и вычисляющей определитель матрицы на основе этого разложения. Найти разложение Холецкого и определитель матрицы Гильберта, для которой

$$a_{ij} = \frac{1}{i+j-1}, \quad i = 1, 2, \dots, n, \quad j = 1, 2, \dots, n$$

при  $n = 4$ .

## Задача 4: Метод Якоби

Написать программу, реализующую метод Якоби с использованием циклов Python (функция `jacobi`) и с векторизованными вычислениями (функция `jacobi_vec`). Сравнить время выполнения этих функций. Написать тестовые функции, проверяющие работу функции `jacobi`.

### Задача 5: Метод Зейделя

Написать программу, реализующую метод Зейделя (функция `seidel`).  
Написать тестовые функции, проверяющие работу функции `seidel`.

### Задача 6: Сравнение методов Якоби и Зейделя

Используя функции из 4 и 5, найти решение задачи системы  $Ax = b$  с трехдиагональной матрицей  $A$ , в которой

$$a_{ii} = 2, \quad a_{ii+1} = -1 - \alpha, \quad a_{ii-1} = -1 + \alpha, \quad i = 1, 2, \dots, n-1,$$

$$a_{00} = 2, \quad a_{01} = -1 - \alpha, \quad a_{n-1n} = -1 + \alpha, \quad a_{nn} = 2,$$

а правая часть

$$b_0 = 1 - \alpha, \quad b_i = 0, \quad i = 1, 2, \dots, n-1, \quad b_n = 1 + \alpha,$$

определяет точное решение  $x_i = 1$ ,  $i = 1, 2, \dots, n$ . Сравнить скорости сходимости (число итераций) методов Якоби и Зейделя при различных параметрах  $n$  и  $\alpha$  при  $0 \leq \alpha \leq 1$ . Для этого построить график зависимости числа итераций  $K$  от  $n$  при фиксированном  $\alpha$ , а также график зависимости числа итераций  $K$  от  $\alpha$  при фиксированном  $n$ .

### Задача 7: Метод верхней релаксации

Написать программу, реализующую приближенное решение системы линейных алгебраических уравнений методами релаксации из 2.1. Написать тестовые функции. Исследовать графически зависимость скорости сходимости этого итерационного метода от итерационного параметра  $\omega$  при численном решении системы уравнений из 6 при различных параметрах  $n$  и  $\alpha$ .

### Задача 8: Метод сопряженных градиентов

С помощью метода сопряженных градиентов (файл [cg.py](#)) найти решение системы  $Ax = b$  с матрицей Гильберта из задачи 3 и правой частью

$$b_i = \sum_{j=1}^n a_{ij}, \quad i = 1, 2, \dots, n,$$

для которой точное решение есть  $x_i = 1$ ,  $i = 1, 2, \dots, n$ . Построить график зависимости числа итераций от  $n$ .

## Предметный указатель

*LU*-разложение, 6

Вектор Гаусса, 5

Итерационный метод

Гаусса — Зейделя, 15

Якоби, 15

невязка, 17

поправка, 17

последовательная верхняя релаксация, 17

сопряженных градиентов, 19

Матрица

перестановок, 9

перестановочная, 9

преобразования Гаусса, 5

Метод Гаусса, 2

обратная подстановка, 3

прямая подстановка, 2

Множители Гаусса, 5